

고의숙 교육감의 "초개별화 맞춤형 교육"

— 벤자민 블룸의 2시그마 문제 논문 요약 —

출처: Benjamin S. Bloom, "The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring" 게재: *Educational Researcher*, Vol. 13, No. 6 (1984), pp. 4-16

저자: 벤저민 블룸(시카고대학교·노스웨스턴대학교 교육학 교수, 교육평가·교수학습 전공) 연계 문서: AI 교육 패러다임 · AX 전환과 교육

한 줄 요약

일대일 개인교습을 받은 학생은 전통적 집단수업 학생보다 약 2 표준편차(2σ) 높은 성취를 보인다. 그러나 개인교습을 모든 학생에게 제공하기엔 비용이 너무 크다 — 이 격차를 대규모로 실현 가능한 방법으로 좁히는 것이 교육 연구의 핵심 과제다(= '2 시그마 문제').

1. 실험 설계 — 세 가지 학습 조건 비교

시카고대학교 박사과정생 아나니아(Anania, 1982-1983)와 버크(Burke, 1984)가 학생을 세 조건에 무작위 배정해 비교했다. 4·5·8학년, 확률·지도학(Cartography) 등 다양한 표본에서 3주·11차시로 반복 검증했다.

조건	방식
① 전통적 수업(Conventional)	교사 1명당 학생 약 30명. 주기적 시험만 실시
② 완전학습(Mastery Learning)	30명 학급 + 형성평가·피드백·교정지도(corrective)·재평가 추가
③ 개인교습(Tutoring)	학생 1명(또는 2~3명)당 전담 교사 1명 + 형성평가·교정 절차

- 세 조건의 초기 적성·성취·태도·흥미는 동일하게 맞췄다.
- 수업 시간도 동일했고, 완전학습·개인교습 조건의 교정 작업 시간만 추가됐다.

2. 결과 — '2 시그마' 효과

표준편차(σ , 시그마)를 기준으로 전통 수업 학급과 비교한 결과:

조건	향상 정도	전통 수업 대비 위치
개인교습(③)	약 $+2\sigma$	평균 학생이 전통 수업 학생의 상위 98% 수준
완전학습(②)	약 $+1\sigma$	평균 학생이 전통 수업 학생의 상위 84% 수준

- **도달률 전환:** 전통 수업에서 **상위 20%만** 도달하던 성취 수준을, 개인교습에서는 **90%**, 완전학습에서는 **70%**의 학생이 도달했다.

3. 부수 효과

- **학습 몰입 시간(time on task):** 전통 65% → 완전학습 75% → 개인교습 90% 이상.
- **태도·흥미:** 개인교습에서 가장 긍정적, 전통 수업에서 가장 낮음.
- **적성-성취 상관 약화:** 사전 적성이 결과를 좌우하는 정도가 개인교습에서 크게 줄었다(상관계수 $+ .60$ → 완전학습 $+ .35$ → 개인교습 $+ .25$). 즉 타고난 적성보다 **'좋은 학습 조건'**이 성취를 결정한다.

4. 핵심 메시지 — '2 시그마 문제'란

가장 좋은 조건(1:1 개인교습)에서 학생은 2σ 향상된다. 그러나 개인교습을 사회 전체에 제공하기엔 비용이 너무 크다.

블룸은 "대부분의 학생이 이 높은 수준에 도달할 잠재력을 가지고 있다"고 강조하며, 연구·교육의 핵심 과제를 다음과 같이 제시한다.

"일대일 개인교습에 근접한 효과를 내면서도, 대규모로 실현 가능한 집단 교수·학습 조건을 찾을 수 있는가?"

이것이 '2 시그마 문제'이며, 이후 완전학습·교정 피드백·적응형 학습 연구의 출발점이 됐다.

5. 블룸에서 AI 초개별화로 — 고전에서 실증으로

블룸의 완전학습은 1960~80년대의 고전이며, 오늘날 적응형 학습·AI 디지털교과서(AIDT)의 개념적 뿌리로 계속 인용된다. 그러나 '개별화·완전학습'에서 한 걸음 더 나아간 '**초개별화**'를 정당화하려면, **AI가 실제로 그 조건을 구현하는가**에 대한 현대적 실증이 필요하다. 이 물음에 답하는 연구는 두 갈래로 축적돼 왔다.

① 생성형 AI 이전 — 지능형 튜터링 시스템(ITS)이 개인교습에 근접

- VanLehn(2011)은 여러 실험을 종합해, **인간 개인교습의 효과가 2σ 라는 통념보다 작으며, 단계형(step-based) ITS는 인간 교사에 근접한 효과를 낸다는 것을 보였다.** 즉 '2 시그마'는 인간에게만 가능한 값이 아니라 **잘 설계된 기술로도 상당 부분 좁힐 수 있는 격차다.**
- Kulik & Fletcher(2016)는 통제된 50개 평가의 메타분석에서 **ITS의 중앙값 효과가 $+0.66\sigma$ (50→75 백분위)**이며 **92%의 연구에서 전통 수업을 능가했다**고 보고했다. 다만 효과 크기는 **평가도구·구현 충실도에 크게 좌우된다고** 단서를 달았다.

② 생성형 AI 시대(2023~) — 최신 무작위통제연구(RCT)의 큰 효과

- Kestin 외(2025, 하버드, *Scientific Reports*)의 RCT에서, **잘 설계된 AI 튜터로 학습한 집단이 활동 중심 수업 집단보다 2배 이상의 학습 이득을 더 짧은 시간에 얻었다**(대학 물리학 단일 과목 결과 — 초·중등 일반화는 자체 시범으로 검증할 문제).
- 나이지리아의 파일럿 RCT(World Bank, 2024)에서도 **생성형 AI(코파일럿·ChatGPT 기반) 튜터를 활용한 중등 영어 수업이 유의한 성취 향상을 보였다**(단기 시범 결과로 지속 효과는 추가 검증 필요; Brookings, 2026 정리).

무엇이 새로운가. 블룸의 완전학습이 '무엇을 해야 하는가'(형성평가+교정으로 개별 숙달)를 규정했다면, 생성형 AI는 **자연어 대화·실시간 적응·낮은 한계비용의 확장성**을 더해 블룸이 넘지 못한 **비용 장벽**을 낮춘다. 곧 **초개별화 = 완전학습의 개별화 + AI의 적응형 대화를, 대규모로.** 이때 AI는 학생마다 **숙달**을 향해 이 「형성평가→교정」 루프를 실시간으로 돌리는 **개인 튜터**가 되고, 교사는 서로 다른 속도로 나아가는 **여러 학생을 조율하는 지휘자**가 된다 — 블룸이 비용 때문에 대규모로 하지 못한 1:1 교습을, 그 구조 그대로 실현하는 셈이다. 구체적으로 형성평가에 **도달한 학생은 다음 목표·심화로** 나아가고, **미도달 학생에게는 AI가 오개념을 짚어 그 학생에게 최적화된 설명·예시·문항을 멀티모달(글·그림·음성)로 실시간 생성해** 다시 학습하고 재 형성평가를 받을 기회를 준다 — 미리 만들어 둔 해설을 골라 보여 주던 이전 세대 ITS와 갈라지는 지점이다.

그러나 신중하게. 위 연구들이 공통으로 말하는 것은 "**AI를 쓰면 무조건 오른다**"가 아니라 "**잘 설계된 AI가 오른다**"이다. 효과는 **튜터 설계·수업 통합·평가 정렬**에 좌우되며(Kulik & Fletcher, 2016), 근거는 아직 **축적 중**이다. 그렇다면 무엇을 '잘 설계'해야 하는가 — 여기서 투자의 방향을 분명히 할 필요가 있다. 그것은 **제주가 콘텐츠를 직접 찍어내는 일이 아니라, 좋은 수업이 일어날 '조건'을 갖추는 일이다.** 그 조건은 셋이다: ㉠ **좋은 재료**(고성능 AI의 공적 보장), ㉢ **좋은 주방**(튜터 프롬프트·수업/평가 도구·전량 기록과 환류), ㉡ **그 도구로 좋은 수업을 설계하는 교사 역량.** 콘텐츠 자체는 교사와 확장 생태계의 몫이다([바당2](#)

개요 §3-3 '공공은 토대·민간은 속도'·기능 9·10). 실제로 교사가 만든 수업 설계는 **1반→8반·이듬해·동료 공유로 활발히 재사용**되지만, 같은 설계라도 **매 학생의 AI 상호작용은 새로 개별화**되어 기록·환류된다 — 플랫폼이 대는 것은 '재료와 주방'이고 '요리'는 매 교실에서 새로 이뤄진다. 따라서 제주의 초개별화는 ① 콘텐츠 생산이 아니라 '재료·주방·교사 역량'에 투자하고 ② 자체 시범으로 효과를 검증하는 전제 위에서 추진해야 한다.

6. 시사점 — 제주 초개별화 맞춤형 교육과의 연결

이 논문은 핵심공약 「한 아이도 놓치지 않는 초개별화 맞춤형 교육」의 이론적 근거가 된다.

- AI가 '2 시그마 문제'의 해법이 될 수 있다. 블룸이 1984년에 "비용 때문에 1:1 교습을 대규모로 못 한다"고 남긴 과제를, 이제 AI가 비용 장벽을 낮춰 모든 학생에게 개인교습에 준하는 조건을 제공함으로써 풀 수 있다 — 공약의 논리적 출발점.
- '초개별화'의 이론적 뿌리. 성장 이력 기반 맞춤 학습·과정 중심 평가는 블룸의 **완전학습(형성평가 + 교정 피드백)**의 AI·디지털 구현에 해당한다(AI 교육 패러다임 §4 평가 전환과 정합).
- **형평성의 근거**. "적성보다 학습 조건이 성취를 결정"한다는 발견은, AI 접근 **공적 보장**이 곧 출발선·성취 격차 해소로 이어진다는 주장을 뒷받침한다.
- **목표 수준의 근거**. "대부분의 학생이 높은 수준에 도달할 잠재력이 있다"는 명제는 '한 아이도 놓치지 않는' 책임교육의 지향과 일치한다.

인용 시 요지: "블룸(1984)은 1:1 개인교습이 집단수업보다 2 표준편차 높은 성취를 낸다는 것을 실증하고, 이를 대규모로 실현할 방법을 찾는 것을 '2 시그마 문제'로 제기했다. AI 활용 맞춤형 교육은 그 비용 장벽을 낮춰 이 문제를 풀 현실적 수단이다."

참고문헌

1. Bloom, B. S. (1968). *Learning for Mastery*. Evaluation Comment, 1(2).
2. Bloom, B. S. (1984). The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring. *Educational Researcher*, 13(6), 4–16.
3. VanLehn, K. (2011). The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems. *Educational Psychologist*, 46(4), 197–221.
<https://doi.org/10.1080/00461520.2011.611369>

4. Kulik, J. A., & Fletcher, J. D. (2016). Effectiveness of Intelligent Tutoring Systems: A Meta-Analytic Review. *Review of Educational Research*, 86(1), 42–78. <https://eric.ed.gov/?id=EJ1090502>

5. Kestin, G., Miller, K., Klales, A., Milbourne, T., & Ponti, G. (2025). AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting. *Scientific Reports*, 15, 17458. <https://www.nature.com/articles/s41598-025-97652-6>

6. Brookings (2026). *What the research shows about generative AI in tutoring*. <https://www.brookings.edu/articles/what-the-research-shows-about-generative-ai-in-tutoring/>

용어 정리

용어	뜻
표준편차(σ , 시그마)	점수 분포의 흩어진 정도. 정규분포에서 $+1\sigma \approx$ 상위 84%, $+2\sigma \approx$ 상위 98% 위치
완전학습(Mastery Learning)	형성평가로 미도달 부분을 확인하고 교정 피드백·재학습을 거쳐 목표 수준에 도달시키는 교수법
형성평가(Formative Test)	학습 도중 이해 정도를 점검해 피드백·교정에 쓰는 평가(성적 산출용 총괄평가와 구별)
교정지도(Corrective)	형성평가에서 드러난 미흡 부분을 보충하는 추가 지도
학습 몰입 시간(Time on Task)	실제로 학습 과제에 집중한 시간의 비율
지능형 튜터링 시스템(ITS)	Intelligent Tutoring System — 학생의 단계별 풀이를 진단해 맞춤 피드백을 주는 컴퓨터 교수 시스템
무작위통제연구(RCT)	Randomized Controlled Trial — 대상을 무작위로 배정해 처치의 효과를 인과적으로 검증하는 연구 설계